

# Técnicas de Aprendizagem Profunda na Análise Comportamental de Motoristas: Revisão Sistemática da Literatura

Lucas Lima

Resumo—FALTANTE

Palavras-chave—Motorista, Análise Comportamental, Deep Learning, Aprendizagem Profunda

## 1 INTRODUÇÃO

A ANÁLISE comportamental, dentro do campo da inteligência artificial, é uma atividade bem difundida e pesquisada, explorando o uso de diversas técnicas de aprendizado, como o aprendizado superficial, *shallow learning*, a lógica difusa e o aprendizado profundo, mais conhecido como *deep learning*. *Deep learning* é um método que aplica técnicas de aprendizado superficial não lineares encadeadas em múltiplos níveis, com a finalidade de aprender tarefas complexas a partir de dados não tratados, LeCun *et al.* [1].

O comportamento de condução pode ser definido como uma sequência de ações segmentáveis e realizadas uma a uma quando há interação entre o motorista e o veículo [2]. Nesta revisão utilizamos a definição acima, mas com uma especificidade ainda maior, além de ser uma sequência de ações, executadas uma a uma, elas devem ocorrer por um período de tempo limitado e ser mensuráveis através de sensores automotivos instalados no veículo.

As sessões seguintes estruturam esta pesquisa conforme a ordem: na seção 2 o protocolo da pesquisa é detalhado, bem como seu objetivo e as questões de pesquisa; na seção 3 são apresentados os resultados obtidos; a discussão sobre o tema ocorre na seção 4; a conclusão deste trabalho e as ameaças à sua validade são expostos nas seções 5 e 6, respectivamente.

## 2 PROTOCOLO DE REVISÃO

Nesta seção são apresentadas todas as diretrizes que guiaram o processo de revisão sistemática da literatura, a fim de atingir os objetos explicitados na seção 2.1.

O modelo de trabalho foi baseado nas diretrizes documentadas pela Kitchenham [3] e executado seguindo três macro etapas: 1) Levantamento bibliográfico; 2) Seleção dos artigos; 3) Análise dos estudos selecionados. A imagem 1 demonstra a sequência iterativa de atividades realizadas dentro de cada macro etapa.

O levantamento bibliográfico foi essencial na definição e refinamento da *string* de busca, discutida com maiores detalhes no item 2.2; e o uso dos filtros de pesquisa serviram para delimitar a abrangência e destacar os resultados que seriam melhor aproveitados para o cumprimento do objetivo deste trabalho. A etapa de seleção encarregou-se da

curadoria do material gerado pelo estágio anterior. Àqueles artigos que não infringiram nenhum dos critérios de exclusão foram reservados para uma análise mais minuciosa e crítica. A conclusão da última macro etapa que consistiu na análise crítica e mapeamento das técnicas de aprendizagem profunda na análise comportamental de motoristas, resultou na seção 4.

### 2.1 Objetivos da revisão sistemática de literatura

A revisão sistemática da literatura tem como objetivo coletar, organizar e entender o estado da arte de projetos de pesquisa que explorem exclusivamente a aplicação de métodos de aprendizagem profunda na análise idiossincrática de condutores veiculares. Além destas características, o estudo limita-se a incluir pesquisas cujo os dados coletados sejam provenientes de sensores instalados no veículo.

Além de propiciar avanços significativos nos campos de reconhecimento de imagens e reconhecimento da fala, a aplicação de *deep learning* também traz melhores resultados quando aplicada em conjuntos de dados grandes e de alta dimensionalidade, se comparada aos métodos tradicionais de aprendizado superficial [1]. Para o objetivo do estudo, esta técnica é particularmente importante, pois as informações que descrevem o comportamento do condutor são classificadas como séries temporais multidimensionais [4]. Aplicada a este contexto, a série de dados descreve o estado atual do veículo, dado um momento específico no tempo, e é composta por medições de diversos sensores como a aceleração, a velocidade, o ângulo do volante, dentre outras mais.

### 2.2 String de busca

A *string* de busca constitui uma das principais partes de uma revisão sistemática da literatura, pois é a partir dela que todo o estudo será conduzido. Caso o conjunto de termos escolhidos não consiga expressar plenamente a necessidade da pesquisa, os resultados oriundos das bases de pesquisa não estarão condizentes com as necessidades do pesquisador. Justamente para evitar o cenário acima, a cadeia de pesquisa empregada neste estudo foi dividida e evoluída iterativamente com o auxílio das plataformas Scopus e Web

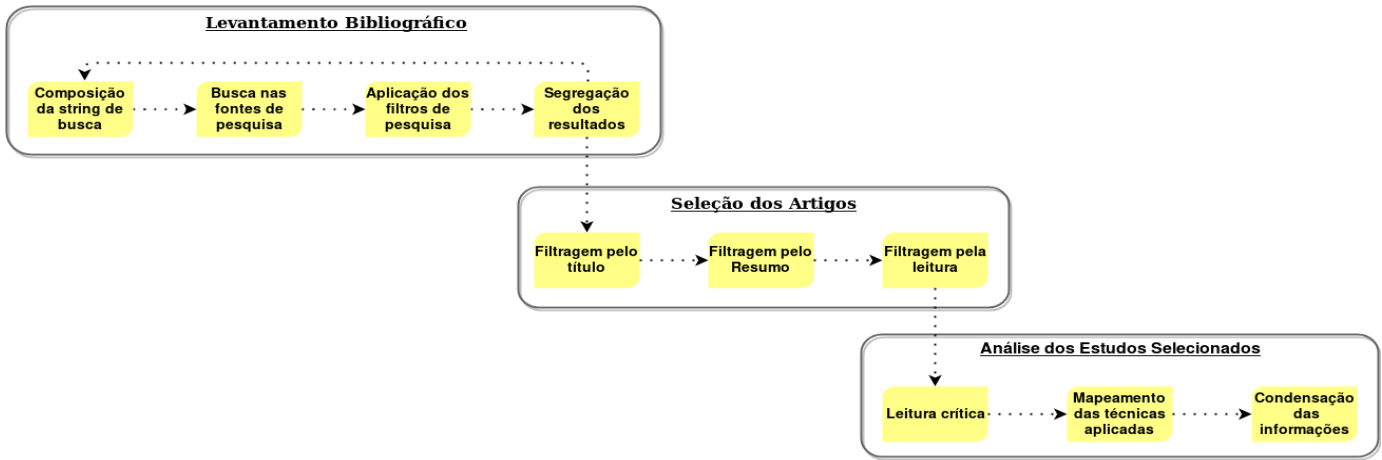


Figura 1. Detalhamento das três macro etapas utilizadas para a confecção desta revisão sistemática da literatura.

of Science. As duas partes da *string* passaram pelo mesmo processo de amadurecimento.

Primeiro um termo genérico foi apresentado às plataformas supracitadas e, a partir das palavras-chaves retornadas, novos termos foram sendo incorporados à cadeia original. A quantidade total de documentos retornados e a quantidade de documentos por área do conhecimento foram as métricas utilizadas para avaliar a inclusão de novos termos.

A *query* de busca pelas técnicas de aprendizagem profunda contem 30 termos. Sem a aplicação de nenhum filtro nos resultados, 43.272 artigos foram retornados pelo Scopus e 24.928 pela Web of Science, uma diferença de 42,39%. Já a busca pelo comportamento do motorista possui 45 termos ao todo e, também sem a aplicação de filtros, a busca nas mesmas bases retornaram 36.968 e 21.548 artigos, respectivamente. Ambas as *queries* podem ser consultadas nas tabelas 1 e 2.

Quando a junção das duas cadeias é feita pelo conector lógico *E*, surge uma nova *string* de busca com 75 termos. Quando esta nova *string* é apresentada às plataformas de pesquisa, os resultados são reduzidos para 161 artigos no Scopus e 83 na Web of Science.

### 2.3 Questões de pesquisa

Kitchenham [3], defende que a definição das questões de pesquisa é o elemento mais importante de qualquer revisão sistemática e isto ocorre porque toda a metodologia da revisão será guiada por estes questionamentos.

No presente estudo foram elaboradas três questões de pesquisa com o objetivo de identificar quais técnicas de aprendizado profundo, aplicadas ao contexto de análise comportamental de condutores, vem sendo utilizadas e quais são as suas vantagens e desvantagens frente à outros modelos. Também houve a preocupação em compreender como os atributos captados do veículo instantaneamente estavam sendo tratados, organizados e apresentados à rede neural. As questões de pesquisa (QP) que nortearam este estudo, e suas justificativas, encontram-se abaixo ordenadas por relevância:

**QP1:** Quais são as arquiteturas de *deep learning* aplicadas na área de reconhecimento do comportamento de motoristas?

**String de busca 1:** Busca por técnicas de *deep learning* considerando o título, resumo e palavras-chave

TITLE-ABS-KEY:

*deep learning* OR *convolutional neural network* OR *convolution\* network* OR *deep neural network* OR *auto encoder* OR *deep belief network* OR *convolutional network* OR *cnn* OR *dbn* OR *deep architecture* OR *autoencoder* OR *deep bayesian network* OR *deep \* network* OR *deep convolution network* OR *deep convolutional network* OR *deep neural convolutional network* OR *deep neural convolution network* OR *deep autoencoder* OR *deep auto encoder* OR *deep \* autoencoder* OR *deep \* auto encoder* OR *dnn* OR *deep multilayer neural network* OR *deep artificial neural network* OR *deep boltzmann machine* OR *deep multitask learning* OR *deep extreme learning machine* OR *deep recurrent neural network* OR *deep rnn* OR *deep fuzzy*

As técnicas de aprendizagem profunda são aplicadas em diversas áreas do conhecimento. Wang [5], utiliza *deep learning* para identificar falhas em turbinas eólicas; Mukherjee [6] aplica a mesma técnica para realizar segmentação de nódulos pulmonares. As técnicas de redes neurais profundas, assim como as técnicas de redes neurais superficiais, podem ser classificadas como *feedforward* ou recorrentes; supervisionadas, semi-supervisionadas, não supervisionadas ou de reforço. Entender a arquitetura utilizada na rede neural, e a sua classificação, é importante para identificar quais redes produzem os melhores resultados considerando os dados apresentados e o tipo de problema que ela foi proposta à resolver.

**QP2:** Como devem ser tratados os casos de outliers e medições que apresentam interferências ou dados corrompidos?

Na atualidade, a captação de dados sensorizados pode ser considerada uma tarefa trivial, por isso os sensores estão presentes nos mais variados objetos do cotidiano.

**String de busca 2:** Busca por comportamento do motorista (*driving behavior*) e variações, considerando o título, resumo e palavras-chave

TITLE-ABS-KEY:

*drive\* identif\* OR drive\* fingerprint\* OR drive\* recogn\* OR drive\* behaviour\* OR drive\* behavior\* OR drive\* model\* OR drive\* perform\* OR drive\* modelling OR drive\* modeling OR drive\* feature OR drive\* mapping OR drive\* characteristic OR drive\* characteristic OR drive\* trait\* OR conductor\* identif\* OR conductor\* fingerprint\* OR conductor\* recogn\* OR conductor\* behaviour\* OR conductor\* behavior\* OR conductor\* model\* OR conductor\* perform\* OR conductor\* modelling OR conductor\* modeling OR conductor\* feature OR conductor\* mapping OR conductor\* characteristic OR conductor\* characteristic OR conductor\* trait\* OR driving identif\* OR driving fingerprint\* OR driving recogn\* OR driving behaviour\* OR driving behavior\* OR driving model\* OR driving perform\* OR driving modelling OR driving modeling OR driving feature OR driving mapping OR driving characteristic OR driving characteristic OR driving trait\* OR driving abilit\* OR driver\* abilit\* OR conductor\* abilit\**

- [2] H. Liu, T. Taniguchi, K. Takenaka, Y. Tanaka, and T. Bando, "Reducing the negative effect of defective data on driving behavior segmentation via a deep sparse autoencoder," 2016.
- [3] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," *Technical Report EBSE 2007-001, Keele University, UK*, 2007.
- [4] H. Liu, T. Taniguchi, K. Takenaka, and T. Bando, "Defect-repairable latent feature extraction of driving behavior via a deep sparse autoencoder," *Sensors (Switzerland)*, vol. 18, no. 2, 2018, cited By 0. [Online]. Available: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85042305285&doi=10.3390%2fs18020608&partnerID=40&md5=9c3938225b4d8302ab95d4846006abd4>
- [5] L. Wang, Z. Zhang, H. Long, J. Xu, and R. Liu, "Wind turbine gearbox failure identification with deep neural networks," *IEEE Transactions on Industrial Informatics*, vol. 13, no. 3, pp. 1360–1368, 2017.
- [6] S. Mukherjee, X. Huang, and R. Bhagalia, "Lung nodule segmentation using deep learned prior based graph cut," 2017, pp. 1205–1208.

Mesmo se tratando de uma atividade simples, existe a possibilidade de falha na leitura, produção de dados ruidosos ou corrompimento das informações. Liu [2] alerta que estes dados defeituosos interferem na capacidade de segmentação do comportamento do motorista. Esta pergunta auxiliou a identificar e entender quais são as estratégias mais utilizadas e adequadas na minimização do impacto causado por dados defeituosos e *outliers*.

**QP3:** *Quais campos sensorizados devem ser apresentados à rede neurais de aprendizado profundo?*

O objetivo desta pergunta é entender se a ordem de apresentação dos dados coletados pelos diferentes sensores acoplados ao veículo altera o desenho da rede *deep learning* durante a execução atividade de segmentação de características do motorista.

## 2.4 Definição das fontes de pesquisa e filtros de resultado

## 2.5 Critérios de inclusão e exclusão

## 3 RESULTADOS DA PESQUISA

### 3.1 Estado da arte

## 4 DISCUSSÃO DOS RESULTADOS

## 5 CONCLUSÃO E OPORTUNIDADES

## 6 AMEAÇAS A VALIDADE DESTE TRABALHO

## REFERÊNCIAS

- [1] Y. Lecun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.