

Técnicas de Aprendizagem Profunda na Análise Comportamental de Motoristas: Revisão Sistemática da Literatura

Lucas Lima

Resumo—As técnicas de *deep learning* e a sua capacidade de aprender tarefas complexas a partir de conjuntos de dados complexos e com grande dimensão, têm atraído cada vez mais atenção e adeptos. A análise comportamental, por ser uma tarefa que exige a identificação de correlações entre os aspectos analisados, torna-se uma candidata natural para a aplicação desta técnica. Neste artigo é feita uma revisão sistemática da literatura com o objetivo de identificar estudos que realizam a tarefa de análise comportamental em conjunto com outras diretrizes que regem a aplicação desta técnica.

Index Terms—Motorista, Análise Comportamental, Deep Learning, Aprendizagem Profunda

1 INTRODUÇÃO

A ANÁLISE comportamental, dentro do campo da inteligência artificial, é uma atividade bastante difundida e pesquisada, explorando o uso de diversas técnicas de aprendizado, como o aprendizado superficial, *shallow learning*, a lógica difusa e o aprendizado profundo, mais conhecido como *deep learning*. *Deep learning* é um método que aplica técnicas de aprendizado superficial não lineares encadeadas em múltiplos níveis, com a finalidade de aprender tarefas complexas a partir de dados não tratados, LeCun *et al.* [26].

O comportamento de condução pode ser definido como uma sequência de ações segmentáveis e realizadas uma a uma quando há interação entre o motorista e o veículo [15]. Nesta revisão utilizamos a definição acima, mas com uma especificidade ainda maior, além de ser uma sequência de ações, executadas uma a uma, elas devem ocorrer por um período de tempo limitado e ser mensuráveis por meio de sensores automotivos instalados no veículo.

As sessões seguintes estruturam esta pesquisa conforme a ordem: na seção 2 o protocolo da pesquisa é detalhado, bem como seu objetivo e as questões de pesquisa; na seção 3 são apresentados os resultados obtidos; a discussão sobre o tema ocorre na seção 4; e a seção 5 é responsável pela conclusão deste trabalho.

2 PROTOCOLO DE REVISÃO

Nesta seção são apresentadas todas as diretrizes que guiaram o processo de revisão sistemática da literatura, a fim de atingir os objetos explicitados na seção 2.1.

O modelo de trabalho foi baseado nas diretrizes documentadas pela Kitchenham [27] e executado seguindo três macro etapas: 1) Levantamento bibliográfico; 2) Seleção dos artigos; 3) Análise dos estudos selecionados. A imagem 1 demonstra a sequência iterativa de atividades realizadas dentro de cada macro etapa.

O levantamento bibliográfico foi essencial na definição e refinamento da *string* de busca, discutida com maiores

detalhes no item 2.2; e o uso dos filtros de pesquisa serviram para delimitar a abrangência e destacar os resultados que seriam melhor aproveitados para o cumprimento do objetivo deste trabalho. A etapa de seleção encarregou-se da curadoria do material gerado pelo estágio anterior. Àqueles artigos que não infringiram nenhum dos critérios de exclusão foram reservados para uma análise mais minuciosa e crítica. A conclusão da última macro etapa que consistiu na análise crítica e mapeamento das técnicas de aprendizagem profunda na análise comportamental de motoristas, resultou na seção 4.

2.1 Objetivos da revisão sistemática de literatura

A revisão sistemática da literatura tem como objetivo coletar, organizar e compreender o estado da arte de projetos de pesquisa que explorem exclusivamente a aplicação de métodos de aprendizagem profunda na análise idiosincrática de condutores veiculares. Além destas características, o estudo limita-se a incluir pesquisas cujo os dados coletados sejam provenientes de sensores instalados no veículo.

Além de propiciar avanços significativos nos campos de reconhecimento de imagens e reconhecimento da fala, a aplicação de *deep learning* também traz melhores resultados quando aplicada em conjuntos de dados grandes e de alta dimensionalidade, se comparada aos métodos tradicionais de aprendizado superficial [26]. Para o objetivo do estudo, esta técnica é particularmente importante, pois as informações que descrevem o comportamento do condutor são classificadas como séries temporais multidimensionais [1]. Aplicada a este contexto, a série de dados descreve o estado atual do veículo, dado um momento específico no tempo, e é composta por medições de diversos sensores como a aceleração, a velocidade, o ângulo do volante, dentre outras mais.

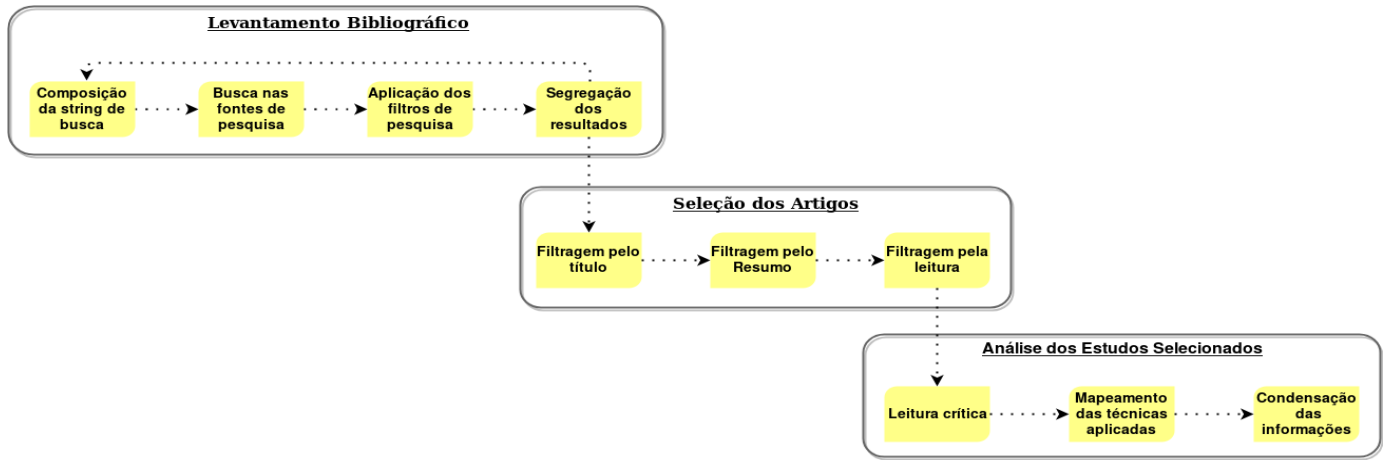


Figura 1. Detalhamento das três macro etapas utilizadas para a confecção desta revisão sistemática da literatura.

2.2 String de busca

A *string* de busca constitui uma das principais partes de uma revisão sistemática da literatura, pois é a partir dela que todo o estudo será conduzido. Caso o conjunto de termos escolhidos não consiga expressar plenamente a necessidade da pesquisa, os resultados oriundos das bases de pesquisa não estarão condizentes com as necessidades do pesquisador. Justamente para evitar o cenário acima, a cadeia de pesquisa empregada neste estudo foi dividida e evoluída iterativamente com o auxílio das plataformas Scopus e Web of Science.

As duas partes da *string* passaram pelo mesmo processo de amadurecimento. Primeiro um termo genérico foi apresentado às plataformas supracitadas e, a partir das palavras-chaves retornadas, novos termos foram sendo incorporados à cadeia original. A quantidade total de documentos retornados e a quantidade de documentos por área do conhecimento foram as métricas utilizadas para avaliar a inclusão de novos termos.

A *query* de busca pelas técnicas de aprendizagem profunda contém 30 termos. Sem a aplicação de nenhum filtro nos resultados, 43.272 artigos foram retornados pelo Scopus e 24.928 pela Web of Science, uma diferença de 57,60%. Já a busca pelo comportamento do motorista possui 45 termos ao todo e, também sem a aplicação de filtros, a busca nas mesmas bases retornaram 36.968 e 21.548 artigos, respectivamente. Ambas as *queries* podem ser consultadas nas tabelas 1 e 2.

Quando a junção das duas cadeias é feita pelo conector lógico *E*, surge uma nova *string* de busca com 75 termos. Quando esta nova *string* é apresentada às plataformas de pesquisa, os resultados são reduzidos para 161 artigos no Scopus e 83 na Web of Science.

2.3 Questões de pesquisa

Kitchenham [27] defende que a definição das questões de pesquisa é o elemento mais importante de qualquer revisão sistemática e isto ocorre porque toda a metodologia da revisão será guiada por estes questionamentos.

No presente estudo foram elaboradas três questões de pesquisa com o objetivo de identificar quais técnicas de

String de busca 1: Busca por técnicas de *deep learning* considerando o título, resumo e palavras-chave

TITLE-ABS-KEY:

deep learning OR *convolutional neural network* OR *convolution* network* OR *deep neural network* OR *auto encoder* OR *deep belief network* OR *convolutional network* OR *cnn* OR *dbn* OR *deep architecture* OR *autoencoder* OR *deep bayesian network* OR *deep * network* OR *deep convolution network* OR *deep convolutional network* OR *deep neural convolutional network* OR *deep neural convolution network* OR *deep autoencoder* OR *deep auto encoder* OR *deep * autoencoder* OR *deep * auto encoder* OR *dnn* OR *deep multilayer neural network* OR *deep artificial neural network* OR *deep boltzmann machine* OR *deep multitask learning* OR *deep extreme learning machine* OR *deep recurrent neural network* OR *deep rnn* OR *deep fuzzy*

aprendizado profundo, aplicadas ao contexto de análise comportamental de condutores, vem sendo utilizadas e quais são as suas vantagens e desvantagens frente à outros modelos. Também houve a preocupação em compreender como os atributos captados do veículo instantaneamente estavam sendo tratados, organizados e apresentados à rede neural. As questões de pesquisa (QP) que nortearam este estudo, e suas justificativas, encontram-se abaixo ordenadas por relevância:

QP1: Quais são as arquiteturas de *deep learning* aplicadas na área de reconhecimento do comportamento de motoristas?

As técnicas de aprendizagem profunda são aplicadas em diversas áreas do conhecimento. Wang [28], utiliza *deep learning* para identificar falhas em turbinas eólicas; Mukherjee [29] aplica a mesma técnica para realizar segmentação de nódulos pulmonares. As técnicas de redes neurais profundas, assim como as técnicas de redes neurais superficiais, podem ser classificadas como *feedforward* ou recorrentes; supervisionadas, semi-supervisionadas, não supervisionadas ou de reforço.

String de busca 2: Busca por comportamento do motorista (*driving behavior*) e variações, considerando o título, resumo e palavras-chave

TITLE-ABS-KEY:

drive identif* OR drive* fingerprint* OR drive* recogn* OR drive* behaviour* OR drive* behavior* OR drive* model* OR drive* perform* OR drive* modelling OR drive* modeling OR drive* feature OR drive* mapping OR drive* characteristic OR drive* characteristic OR drive* trait* OR conductor* identif* OR conductor* fingerprint* OR conductor* recogn* OR conductor* behaviour* OR conductor* behavior* OR conductor* model* OR conductor* perform* OR conductor* modelling OR conductor* modeling OR conductor* feature OR conductor* mapping OR conductor* characteristic OR conductor* characteristic OR conductor* trait* OR driving identif* OR driving fingerprint* OR driving recogn* OR driving behaviour* OR driving behavior* OR driving model* OR driving perform* OR driving modelling OR driving modeling OR driving feature OR driving mapping OR driving characteristic OR driving characteristic OR driving trait* OR driving abilit* OR driver* abilit* OR conductor* abilit**

Entender a arquitetura utilizada na rede neural, e a sua classificação, é importante para identificar quais redes produzem os melhores resultados considerando os dados apresentados e o tipo de problema que ela foi proposta à resolver.

QP2: *Como devem ser tratados os casos de outliers e medições que apresentam interferências ou dados corrompidos?*

Na atualidade, a captação de dados sensorizados pode ser considerada uma tarefa trivial, por isso os sensores estão presentes nos mais variados objetos do cotidiano. Mesmo se tratando de uma atividade simples, existe a possibilidade de falha na leitura, produção de dados ruidosos ou corrompimento das informações. Liu [15] alerta que estes dados defeituosos interferem na capacidade de segmentação do comportamento do motorista. Esta pergunta auxiliou a identificar e entender quais são as estratégias mais utilizadas e adequadas na minimização do impacto causado por dados defeituosos e *outliers*.

QP3: *Quais campos sensorizados devem ser apresentados às redes neurais de aprendizado profundo?*

O objetivo desta pergunta é entender se a ordem de apresentação dos dados coletados pelos diferentes sensores acoplados ao veículo, altera o desempenho da rede *deep learning* durante a execução da atividade de segmentação de características do motorista.

2.4 Definição das fontes de pesquisa e filtros de resultado

A escolha das fontes de pesquisa ocorreu durante a primeira macro etapa deste projeto, a etapa de levantamento

bibliográfico. A escolha das fontes de pesquisa não pode ser banalizada ou tratada com menor importância, pois elas serão responsáveis por entregar o corpo de textos a serem trabalhados nas demais etapas da revisão sistemática de literatura.

Na composição deste trabalho foram escolhidas duas bases de dados, a Scopus e a Web of Science. Outras fontes foram descartadas devido ao número de estudos retornados ser inferior, quando comparado às fontes de pesquisa previamente citadas, e por apresentarem artigos que já haviam sido mapeados.

Após a execução da *string* de busca nas duas fontes de pesquisa selecionadas, foi necessário refinar os resultados aplicando-lhes filtros restritivos. Primeiramente a área do conhecimento foi restringida à Ciência da Computação, Engenharia, Matemática e Ciências da Decisão; o segundo passo foi desconsiderar estudos que não estivessem na língua inglesa; finalmente, foram desprezados artigos que não eram classificados como artigos de conferência, artigos e artigos na imprensa. Não foi preciso restringir a procura à um período específico de tempo porque, para este estudo, era importante entender a evolução do uso das técnicas de aprendizado profundo.

Os parâmetros de busca tanto do Scopus quanto da Web of Science estão disponíveis integralmente em 3 e 4, respectivamente.

2.5 Critérios de inclusão e exclusão

Os critérios de inclusão e exclusão se encarregaram da triagem dos artigos que continham todas as premissas necessárias para se atingir o objetivo desta pesquisa. Cada um dos critérios foi aplicado em um momento distinto da revisão, os critérios de inclusão foram empregados na atividade *Segregação dos resultados*, pertencente à etapa do levantamento bibliográfico, e os critérios de exclusão foram adotados nas atividades de *Filtragem pelo resumo* e *Filtragem pela leitura*, concernente à etapa de seleção dos artigos.

1) Critérios de inclusão aplicados:

- Faz uso de técnicas de *deep learning*
- Realizada análise do comportamento do motorista
- Utiliza dados provenientes de sensores

2) Critérios de exclusão

- Escrito em outro idioma senão o inglês
- Não descreve os procedimentos de análise comportamental
- Dados sensorizados provenientes de celulares ou outros dispositivos não-embarcados
- Não descreve os dados coletados do veículo

3 RESULTADOS DA PESQUISA

Após a execução das *strings* de busca em cada uma das bases de pesquisa, foram apurados, ao todo, 172 artigos não únicos, 116 provenientes da plataforma Scopus e 56 da Web of Science. A seguir, os dois grupos de artigos foram unificados em uma coleção de 124 artigos únicos. A base de pesquisa Scopus foi a que mais retornou artigos e também a que mais retornou artigos únicos, são 67 contra 9 da Web of Science.

String de busca 3: String de busca específica utilizada na plataforma Scopus para pesquisar por *deep learning* e comportamento do motorista (*driving behavior*), considerando variações linguísticas. A pesquisa é realizada considerando o título, o resumo e as palavras-chave

```
(
  TITLE-ABS-KEY (deep learning OR convolutional neural network OR convolution * network OR deep neural network
  OR auto encoder OR deep belief network OR convolutional network OR cnn OR dbn OR deep architecture OR
  autoencoder OR deep bayesian network OR deep * network OR deep convolution network OR deep convolutional
  network OR deep neural convolutional network OR deep neural convolution network OR deep autoencoder OR deep auto
  encoder OR deep * autoencoder OR deep * auto encoder OR dnn OR deep multilayer neural network OR deep artificial
  neural network OR deep boltzmann machine OR deep multitask learning OR deep extreme learning machine OR deep
  recurrent neural network OR deep rnn OR deep fuzzy )
  AND
  TITLE-ABS-KEY (drive* identif* OR drive* fingerprint* OR drive* recogn* OR drive* behaviour* OR drive* behavior*
  OR drive* model* OR drive* perform* OR drive* modelling OR drive* modeling OR drive* feature OR drive* mapping
  OR drive* characteristic OR drive* characteristical OR drive* trait* OR conductor* identif* OR conductor* fingerprint*
  OR conductor* recogn* OR conductor* behaviour* OR conductor* behavior* OR conductor* model* OR conductor*
  perform* OR conductor* modelling OR conductor* modeling OR conductor* feature OR conductor* mapping OR
  conductor* characteristic OR conductor* characteristical OR conductor* trait* OR driving identif* OR driving
  fingerprint* OR driving recogn* OR driving behaviour* OR driving behavior* OR driving model* OR driving perform*
  OR driving modelling OR driving modeling OR driving feature OR driving mapping OR driving characteristic OR
  driving characteristical OR driving trait* OR driving abilit* OR driver* abilit* OR conductor* abilit*)
)
AND (
  LIMIT-TO ( SUBJAREA , "COMP") OR LIMIT-TO ( SUBJAREA , "ENGI") OR LIMIT-TO ( SUBJAREA , "MATH")
  OR LIMIT-TO ( SUBJAREA , "DECI" ) ) AND ( EXCLUDE ( DOCTYPE , "re" ) ) AND ( EXCLUDE ( DOCTYPE ,
  "ch" ) ) AND ( EXCLUDE ( DOCTYPE , "cr" ) )
)
```

A imagem 2 mostra o resultado da seleção dos artigos únicos após a aplicação dos critérios de inclusão. A verificação de aderência foi realizada em conjunto com as atividades *Filtragem pelo título* e *Filtragem pelo Resumo*, mesmo assim 15 artigos foram classificados como *incertos* pois nem o título nem o resumo dos textos eram claros o suficiente para a tomada de decisão. Devido a quantidade de artigos desconsiderados ser alta, os estudos classificados incertos foram selecionados para leitura.

A média de artigos desconsiderados porque não atendiam completamente aos critérios de inclusão é 62,33%, sendo que a regra relacionada ao uso de dados sensoriais dos automotivos possui a maior porcentagem, 42,61% das exclusões.

Ao todo, foram selecionados 25 artigos para análise crítica, disponibilizados na tabela 1 junto com a identificação dos autores e ano de publicação. Esta tarefa tinha como alvo, além de responder as questões de pesquisa já enunciada, entender profundamente quais procedimentos precisam ser realizados para a segmentação do comportamento do condutor, quais dados precisam coletados do veículo para realizar tal segmentação, quais métodos de comparação foram utilizados para avaliação e detecção de falsos-positivos e assimilar quais procedimentos devem ser utilizados no tratamento dos dados coletados e como disponibilizá-los para a rede neural.

Ao término da tarefa acima, 15 pesquisas precisaram ser descartadas pois não atendiam plenamente aos critérios de inclusão, a maioria tratava-se de estudos rotulados como incertos. Os dois principais fatores que levaram a exclusão foi a utilização de dispositivos móveis, como celulares, GPS

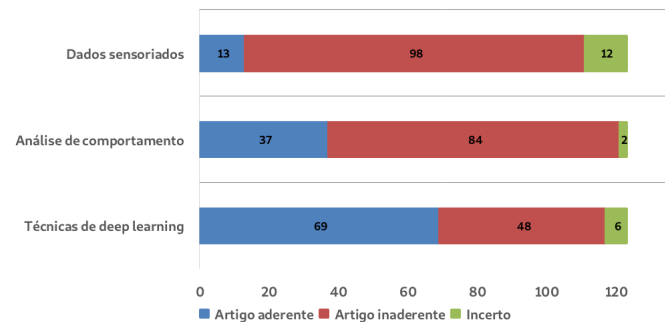


Figura 2. Aderência dos artigos únicos aos critérios de inclusão. Os artigos que atendem a todos os critérios estão rotulados como aderentes, os que descumprem pelo menos uma das exigências são marcados como inaderentes.

e outros dispositivos não embarcados, e o uso de imagens, capturadas em tempo real por câmeras instaladas no veículo ou usando conjunto de dados públicos, para realizar a atividade de análise comportamental do motorista. Os 8 artigos restantes [14], [20], [3], [1], [18], [15], [8] e [21] cumprem rigorosamente todos os critérios de inclusão e não se enquadram em nenhum dos critérios de exclusão, por isso a discussão dos resultados, apresentada na próxima sessão, será realizada baseando-se nos estudos em questão.

String de busca 4: String de busca específica utilizada na plataforma Web of Science para pesquisar por *deep learning* e comportamento do motorista (*driving behavior*), considerando variações linguísticas. A pesquisa é realizada considerando o tópico e título

```
(
TS=(deep learning OR convolutional neural network OR convolution * network OR deep neural network OR auto encoder
OR deep belief network OR convolutional network OR cnn OR dbn OR deep architecture OR autoencoder OR deep
bayesian network OR deep * network OR deep convolution network OR deep convolutional network OR deep neural
convolutional network OR deep neural convolution network OR deep autoencoder OR deep auto encoder OR deep *
autoencoder OR deep * auto encoder OR dnn OR deep multilayer neural network OR deep artificial neural network OR
deep boltzmann machine OR deep multitask learning OR deep extreme learning machine OR deep recurrent neural
network OR deep rnn OR deep fuzzy )
AND
TS=(drive* identif* OR drive* fingerprint* OR drive* recogn* OR drive* behaviour* OR drive* behavior* OR drive*
model* OR drive* perform* OR drive* modelling OR drive* modeling OR drive* feature OR drive* mapping OR drive*
characteristic OR drive* characteristical OR drive* trait* OR conductor* identif* OR conductor* fingerprint* OR
conductor* recogn* OR conductor* behaviour* OR conductor* behavior* OR conductor* model* OR conductor* perform*
OR conductor* modelling OR conductor* modeling OR conductor* feature OR conductor* mapping OR conductor*
characteristic OR conductor* characteristical OR conductor* trait* OR driving identif* OR driving fingerprint* OR
driving recogn* OR driving behaviour* OR driving behavior* OR driving model* OR driving perform* OR driving
modelling OR driving modeling OR driving feature OR driving mapping OR driving characteristic OR driving
characteristical OR driving trait* OR driving abilit* OR driver* abilit* OR conductor* abilit* )
)
OR
(
TI=(deep learning OR convolutional neural network OR convolution * network OR deep neural network OR auto
encoder OR deep belief network OR convolutional network OR cnn OR dbn OR deep architecture OR autoencoder
OR deep bayesian network OR deep * network OR deep convolution network OR deep convolutional network OR
deep neural convolutional network OR deep neural convolution network OR deep autoencoder OR deep auto encoder
OR deep * autoencoder OR deep * auto encoder OR dnn OR deep multilayer neural network OR deep artificial neural
network OR deep boltzmann machine OR deep multitask learning OR deep extreme learning machine OR deep
recurrent neural network OR deep rnn OR deep fuzzy )
AND
TI=(drive* identif* OR drive* fingerprint* OR drive* recogn* OR drive* behaviour* OR drive* behavior* OR drive*
model* OR drive* perform* OR drive* modelling OR drive* modeling OR drive* feature OR drive* mapping OR
drive* characteristic OR drive* characteristical OR drive* trait* OR conductor* identif* OR conductor* fingerprint*
OR conductor* recogn* OR conductor* behaviour* OR conductor* behavior* OR conductor* model* OR conductor*
perform* OR conductor* modelling OR conductor* modeling OR conductor* feature OR conductor* mapping OR
conductor* characteristic OR conductor* characteristical OR conductor* trait* OR driving identif* OR driving
fingerprint* OR driving recogn* OR driving behaviour* OR driving behavior* OR driving model* OR driving
perform* OR driving modelling OR driving modeling OR driving feature OR driving mapping OR driving
characteristic OR driving characteristical OR driving trait* OR driving abilit* OR driver* abilit* OR conductor*
abilit* )
)
```

Refined by: WEB OF SCIENCE CATEGORIES: (COMPUTER SCIENCE ARTIFICIAL INTELLIGENCE OR
ENGINEERING MULTIDISCIPLINARY OR COMPUTER SCIENCE CYBERNETICS OR COMPUTER SCIENCE
INFORMATION SYSTEMS OR COMPUTER SCIENCE INTERDISCIPLINARY APPLICATIONS OR
COMPUTER SCIENCE THEORY METHODS OR MATHEMATICS INTERDISCIPLINARY APPLICATIONS OR
ENGINEERING ELECTRICAL ELECTRONIC)

Indexes=SCI-EXPANDED, SSCI, A&HCI, CPCI-S, CPCI-SSH, ESCI Timespan=All years

Tabela 1
Lista dos artigos que atendem aos critérios de inclusão e que fizeram parte da etapa *Análise dos estudos selecionados*.

Artigo	Autores	Ano
A framework for evaluating aggressive driving behaviors based on in-vehicle driving records	Lee J., Jang K.	2017
A hybrid Bayesian Network approach to detect driver cognitive distraction	Liang Y., Lee J.D.	2014
A neural network-based autonomous articulated vehicle system considering driver behavior	Zhang W.-M., Han H.-B., Yang J., Yi X.	2016
A rule-based neural network approach to model driver naturalistic behavior in traffic	Chong L., Abbas M.M., Medina Flintsch A., Higgs B.	2013
Adding Intelligence to Cars Using the Neural Knowledge DNA	Zhang H., Li F., Wang J., Wang Z., Shi L., Zhao J., Sanin C., Szczerbicki E.	2017
Analysis of driving skills based on deep learning using stacked autoencoders	Kagawa T., Chandrasiri N.P.	2017
Brain-inspired Cognitive Model with Attention for Self-Driving Cars	Chen S., Zhang S., Shang J., Chen B., Zheng N.	2017
Cognitive and personality determinants of fitness to drive	Sommer M., Herle M., Häusler J., Risser R., Schützhofer B., Chaloupka Ch.	2008
Context-aware driver behavior detection system in intelligent transportation systems	Al-Sultan S., Al-Bayatti A.H., Zedan H.	2013
DarNet: A deep learning solution for distracted driving detection	Streiffer C., Raghavendra R., Benson T., Srivatsa M.	2017
Deep Learning based Traffic Direction Sign Detection and Determining Driving Style	Karaduman M., Eren H.	2017
DeepSafeDrive: A grammar-aware driver parsing approach to Driver Behavioral Situational Awareness (DB-SAW)	Le T.H.N., Zhu C., Zheng Y., Luu K., Savvides M.	2017
Defect-repairable latent feature extraction of driving behavior via a deep sparse autoencoder	Liu H., Taniguchi T., Takenaka K., Bando T.	2018
Design of a Speed Assistant to Minimize the Driver Stress	Liu H., Taniguchi T., Takenaka K., Bando T.	2018
Driver-Behavior Modeling Using On-Road Driving Data: A new application for behavior signal processing	Miyajima C., Takeda K.	2016
Essential feature extraction of driving behavior using a deep learning method	Liu H., Taniguchi T., Tanaka Y., Takenaka K., Bando T.	2015
Learning driver behavior models from traffic observations for decision making and planning	Gindele T., Brechtel S., Dillmann R.	2015
Multi-CNN and decision tree based driving behavior evaluation	Yin S., Duan J., Ouyang P., Liu L., Wei S.	2017
Nonintrusive detection of driver cognitive distraction in real time using Bayesian networks	Liang Y., Lee J.D., Reyes M.L.	2007
Reducing the negative effect of defective data on driving behavior segmentation via a deep sparse autoencoder	Liu H., Taniguchi T., Takenaka K., Tanaka Y., Bando T.	2016
Toward Intelligent Vehicle Intrusion Detection Using the Neural Knowledge DNA	Li F., Zhang H., Wang J., Liu Y., Gao L., Xu X., Sanin C., Szczerbicki E.	2018
Toward Safer Highways: Predicting Driver Stress in Varying Conditions on Habitual Routes	Magana V.C., Munoz-Organero M.	2017
Towards neuroimaging real-time driving using convolutional neural networks: Development of CNNs for autonomous steering in the TORCS environment	Musoles C.F.	2017
Visualization of Driving Behavior Based on Hidden Feature Extraction by Using Deep Learning	Liu H., Taniguchi T., Tanaka Y., Takenaka K., Bando T.	2017
Visualization of driving behavior using deep sparse autoencoder	Liu H., Taniguchi T., Takano T., Tanaka Y., Takenaka K., Bando T.	2014

4 DISCUSSÃO DOS RESULTADOS

Esta sessão tem o objetivo de discorrer de forma crítica sobre os artigos da tabela 2 e de responder as três questões de pesquisa enunciadas na seção 2.3 baseando-se nos estudos e práticas dos artigos mencionados anteriormente.

A primeira questão de pesquisa está relacionada a identificação das arquiteturas de redes neurais profundas que foram utilizadas no processo de análise comportamental dos motoristas, e a partir das leituras realizadas foi identificado que 7 estudos utilizam *deep auto encoder*, podendo variar em *deep sparse auto encoder* ou *stacked auto encoder*; o estudo restante aplicou *dynamic bayesian network*.

Os trabalhos mais completos foram os desenvolvidos pelo Liu, H. [18], [15], [21], [8] e [1] porque além de apresentarem as fundamentações teóricas, utilizam técnicas como PCA, e algumas de suas variações, para avaliar dissimilaridades entre as aplicações dos algoritmos em diferentes conjuntos de dados. As pesquisas sob sua liderança apresentam uma maturidade acima das encontradas nos demais artigos, também quando comparado ao grupo original de 25 artigos.

O artigo *Defect-repairable latent feature extraction of driving behavior via a deep sparse autoencoder* [1] é o único que aborda sistematicamente a preocupação e a aplicação de informações contendo ruídos ou *outliers*. O estudo propõe o uso de um *deep sparse auto encoder* (DSAE) treinado com o objetivo de recuperar as características originais dos dados corrompidos. A medição da qualidade é feita comparando seu desempenho com outras implementações de DSAE, cuja diferença está na função de ativação ou na maneira de propagação do erro através da rede neural profunda, e com algumas implementações de PCA. Algo que foi notado é o uso das mesmas técnicas já supracitadas ao efetuar as comparações de qualidade.

No que diz respeito as características coletadas do veículo em tempo real, foram apresentadas as seguintes:

- Taxa de abertura do acelerador
- Pressão do cilindro mestre do freio
- Ângulo de viragem
- Velocidade das rodas
- Leituras de medidor de velocidade
- Velocidade do motor
- Aceleração longitudinal
- Aceleração lateral
- Taxa de guinada

Nas pesquisas realizadas pela equipe do Liu, H., os campos são combinados aleatoriamente, gerando pelo menos 8 *datasets* diferentes para comparar o desempenho do DSAE em cada uma das situações. Nas demais pesquisas não há justificativas para a ordem de atributos utilizada no conjunto de dados.

5 CONCLUSÃO E OPORTUNIDADES

Conforme é possível observar na imagem 3, o interesse pelos artigos utilizados nesta pesquisa têm atraído crescente atenção da comunidade. A popularização das técnicas de deep learning se deve principalmente aos avanços conquistados graças à sua capacidade de aprender tarefas complexas. Entretanto, conforme as atividades desta pesquisa

avançavam foi perceptível a escassez de trabalhos que abordassem a análise comportamental de motoristas conforme estruturado na seção 2.

Uma parcela considerável dos artigos precisou ser desconsiderada por utilizar celulares na captura de informações veiculares, e a justificativa dada pelos autores, quando presente, recaía no preço para se adquirir o equipamento embarcado de leitura. Também foram descartados artigos que analisavam características fisiológicas dos motoristas como se fossem comportamentais. Apesar dos contra-pontos citados acima, os trabalhos que atendiam as necessidades impostas demonstravam com clareza e objetividade a forma de condução da pesquisa, as técnicas aplicadas e os resultados obtidos. Dentre estes artigos, aqueles produzidos pelo auto Liu, H. possuíam maturidade acima dos outros. A pesquisa conduzida por ele iniciou no ano de 2015 e vem evoluído deste então.

Ao final deste estudo é claro que as *strings* de busca precisam ser revisadas, tanto para facilitar sua leitura e entendimento quanto para aumentar a quantidade de pesquisas devolvidas pelas fontes de pesquisa. Também é possível explorar outras plataformas de indexação de artigos com a finalidade de aumentar a diversidade de artigos disponíveis para estudo.

REFERÊNCIAS

- [1] H. Liu, T. Taniguchi, K. Takenaka, and T. Bando, "Defect-repairable latent feature extraction of driving behavior via a deep sparse autoencoder," *Sensors (Switzerland)*, vol. 18, no. 2, 2018.
- [2] F. Li, H. Zhang, J. Wang, Y. Liu, L. Gao, X. Xu, C. Sanin, and E. Szczerbicki, "Toward intelligent vehicle intrusion detection using the neural knowledge dna," *Cybernetics and Systems*, pp. 1–8, 2018.
- [3] T. Kagawa and N. Chandrasiri, "Analysis of driving skills based on deep learning using stacked autoencoders," vol. 2017-December, 2017.
- [4] C. Streiffer, R. Raghavendra, T. Benson, and M. Srivatsa, "Darnet: A deep learning solution for distracted driving detection," 2017, pp. 22–28.
- [5] V. Magana and M. Munoz-Organero, "Toward safer highways: Predicting driver stress in varying conditions on habitual routes," *IEEE Vehicular Technology Magazine*, vol. 12, no. 4, pp. 69–76, 2017.
- [6] M. Karaduman and H. Eren, "Deep learning based traffic direction sign detection and determining driving style," 2017, pp. 1046–1050.
- [7] T. Kagawa and N. Chandrasiri, "Analysis of driving skills based on deep learning using stacked autoencoders," vol. 4, 2017, pp. 719–722.

Tabela 2

Listagem dos artigos que não infringem nenhum dos critérios de inclusão e não se enquadram em nenhum dos critérios de exclusão.

Artigo	Autores	Ano
A framework for evaluating aggressive driving behaviors based on in-vehicle driving records	Lee J., Jang K.	2017
A hybrid Bayesian Network approach to detect driver cognitive distraction	Liang Y., Lee J.D.	2014
Analysis of driving skills based on deep learning using stacked autoencoders	Kagawa T., Chandrasiri N.P.	2017
Defect-repairable latent feature extraction of driving behavior via a deep sparse autoencoder	Liu H., Taniguchi T., Takenaka K., Bando T.	2018
Essential feature extraction of driving behavior using a deep learning method	Liu H., Taniguchi T., Tanaka Y., Takenaka K., Bando T.	2015
Reducing the negative effect of defective data on driving behavior segmentation via a deep sparse autoencoder	Liu H., Taniguchi T., Takenaka K., Tanaka Y., Bando T.	2016
Visualization of Driving Behavior Based on Hidden Feature Extraction by Using Deep Learning	Liu H., Taniguchi T., Tanaka Y., Takenaka K., Bando T.	2017
Visualization of driving behavior using deep sparse autoencoder	Liu H., Taniguchi T., Takano T., Tanaka Y., Takenaka K., Bando T.	2014




Figura 3. Evolução das citações dos 25 artigos selecionados para análise crítica

- [8] H. Liu, T. Taniguchi, Y. Tanaka, K. Takenaka, and T. Bando, "Visualization of driving behavior based on hidden feature extraction by using deep learning," *IEEE Transactions on Intelligent Transportation Systems*, vol. 18, no. 9, pp. 2477–2489, 2017.
- [9] S. Chen, S. Zhang, J. Shang, B. Chen, and N. Zheng, "Brain-inspired cognitive model with attention for self-driving cars," *IEEE Transactions on Cognitive and Developmental Systems*, 2017.
- [10] T. Le, C. Zhu, Y. Zheng, K. Luu, and M. Savvides, "Deepsafedrive: A grammar-aware driver parsing approach to driver behavioral situational awareness (db-saw)," *Pattern Recognition*, vol. 66, pp. 229–238, 2017.
- [11] H. Zhang, F. Li, J. Wang, Z. Wang, L. Shi, J. Zhao, C. Sanín, and E. Szczerbicki, "Adding intelligence to cars using the neural knowledge dna," *Cybernetics and Systems*, vol. 48, no. 3, pp. 267–273, 2017.
- [12] S. Yin, J. Duan, P. Ouyang, L. Liu, and S. Wei, "Multi-cnn and decision tree based driving behavior evaluation," vol. Part F128005, 2017, pp. 1424–1429.
- [13] C. Musoles, "Towards neuroimaging real-time driving using convolutional neural networks: Development of cnns for autonomous steering in the torcs environment," 2017, pp. 130–135.
- [14] J. Lee and K. Jang, "A framework for evaluating aggressive driving behaviors based on in-vehicle driving records," *Transportation Research Part F: Traffic Psychology and Behaviour*, 2017.
- [15] H. Liu, T. Taniguchi, K. Takenaka, Y. Tanaka, and T. Bando, "Reducing the negative effect of defective data on driving behavior segmentation via a deep sparse autoencoder," 2016.
- [16] W.-M. Zhang, H.-B. Han, J. Yang, and X. Yi, "A neural network-based autonomous articulated vehicle system considering driver behavior," *Huanan Ligong Daxue Xuebao/Journal of South China University of Technology (Natural Science)*, vol. 44, no. 12, pp. 74–80, 2016.
- [17] C. Miyajima and K. Takeda, "Driver-behavior modeling using on-road driving data: A new application for behavior signal processing," *IEEE Signal Processing Magazine*, vol. 33, no. 6, pp. 14–21, 2016.
- [18] H. Liu, T. Taniguchi, Y. Tanaka, K. Takenaka, and T. Bando, "Essential feature extraction of driving behavior using a deep learning method," vol. 2015-August, 2015, pp. 1054–1060.
- [19] T. Gindele, S. Brechtel, and R. Dillmann, "Learning driver behavior models from traffic observations for decision making and planning," *IEEE Intelligent Transportation Systems Magazine*, vol. 7, no. 1, pp. 69–79, 2015.
- [20] Y. Liang and J. Lee, "A hybrid bayesian network approach to detect driver cognitive distraction," *Transportation Research Part C: Emerging Technologies*, vol. 38, pp. 146–155, 2014.
- [21] H. Liu, T. Taniguchi, T. Takano, Y. Tanaka, K. Takenaka, and T. Bando, "Visualization of driving behavior using deep sparse autoencoder," 2014, pp. 1427–1434.
- [22] L. Chong, M. Abbas, A. Medina Flintsch, and B. Higgs, "A rule-based neural network approach to model driver naturalistic behavior in traffic," *Transportation Research Part C: Emerging Technologies*, vol. 32, pp. 207–223, 2013.
- [23] S. Al-Sultan, A. Al-Bayatti, and H. Zedan, "Context-aware driver behavior detection system in intelligent transportation systems," *IEEE Transactions on Vehicular Technology*, vol. 62, no. 9, pp. 4264–4275, 2013.
- [24] M. Sommer, M. Herle, J. Häusler, R. Risser, B. Schützhofer, and C. Chaloupka, "Cognitive and personality determinants of fitness to drive," *Transportation Research Part F: Traffic Psychology and Behaviour*, vol. 11, no. 5, pp. 362–375, 2008.
- [25] Y. Liang, J. Lee, and M. Reyes, "Nonintrusive detection of driver cognitive distraction in real time using bayesian networks," *Transportation Research Record*, no. 2018, pp. 1–8, 2007.
- [26] Y. Lecun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [27] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," *Technical Report EBSE 2007-001, Keele University, UK*, 2007.
- [28] L. Wang, Z. Zhang, H. Long, J. Xu, and R. Liu, "Wind turbine gearbox failure identification with deep neural networks," *IEEE Transactions on Industrial Informatics*, vol. 13, no. 3, pp. 1360–1368, 2017.
- [29] S. Mukherjee, X. Huang, and R. Bhagalia, "Lung nodule segmentation using deep learned prior based graph cut," 2017, pp. 1205–1208.